

Qwen-only 报告生成-单评委评价流水线的两轮运行级重复验收与软件主控原生 SSH 冒烟：一个有界、回执驱动、可审计的方法学报告

标题为暂定，正式定稿前待定。

稿次：v2（2026-09-07，peerreview 三角色独立审稿后一轮返修）；语种：中文方法学论文初稿；目标刊：npj Imaging（venue-npj-imaging-2026，已登记）。

v1 已登记（rav_10c82c34-2fea-489b-8113-1ab7701ea5a7）；v2 为本轮唯一返修稿，逐条响应见文末「10 返修响应表」。

写作依据：仅使用本 campaign 登记文档（.oph/research/rc_6eb0b1bf-da7c-491e-b754-13b8593b44f5/documents/ study-55f3db62aae3602d.json [study v1] 、resultsreview-509e636ffa99ec51.json [decision=supported] 、experiment-4894ae70bd4adc68.json [冒烟] 、experiment-2b8c1f2504d6a52e.json [32 项审计] 、venue-69a0b1e522207b1f.json 、evidence-*.json）与本机聚合材料（independent-review-original.json、qwenonly-results-bundle-20260907/、antivegf-live-acceptance-20260907/、qwenonly_engineering_report_20260907.md、experiment_handoff.md 顶部校订块）。

本文稿不新增任何数字、不弱化任何局限；所有主张只取自己登记复核文档且逐字保留；研究验证不作临床可用表述。

稿件元信息与待补清单（投稿前必填，本稿不虚构）

项目	状态
作者与单位	待补（按真实课题组成员填写，本稿不虚构作者/机构）
通讯作者与邮箱	待补
利益冲突声明	待补（npj Imaging 要求通讯作者提交全体作者签署的竞争利益声明，无利益亦须声明）
基金与资助	待补
伦理与知情同意	本研究对象为运行回执（run-record）级聚合对象与已冻结的脱敏文本开发任务，不涉及新受试者数据采集；原始影像与直接标识符全程不离开授权服务器。本稿不虚构伦理批件；如刊社要求，伦理说明按真实情况补述
数据/代码存放	服务器端聚合与回执存放见「数据与代码可用性」，访问边界见同节
报告清单（reporting summary）	npj 相关规则要求送审时附完整报告摘要文档；本文为方法学报告，投稿前按刊社模板评估适用项并完成（不宣称已满足任何临床报告规范的完整合规）

缩写：LLM=large language model（大语言模型）；run-record=运行记录级；receipt=回执；A4=评分清单条目编号（内容留驻服务器，见局限）。

摘要

背景：大语言模型在医疗与医学影像领域被快速采用，催生了系列报告规范（TRIPOD-LLM、DECIDE-AI、CONSORT-AI 与医学影像 AI 的 CLAIM），但把规范的关注点（透明度、人工监督、任务特异表现、可复现性）落实到「LLM 自动生成-自动评价」工程流水线的运行级验收上，仍缺少以回执与哈希为证据锚的可审计方法学示例；同时 LLM-as-judge 偏倚（位置、冗长、自增强与自偏好）已为文献所记录。

目的：报告一项方法学研究：在同一批 10 个冻结脱敏 development 任务上，对 Qwen-only debug-json 单臂流水线（父臂生成 qwen3.7-plus 10 份报告 + 独立上下文评分 qwen3.7-max 10 次）进行两轮运行级重复验收（repair-v2 与 live-acceptance，同批输入、非 20 例独立样本），并新增最小软件执行链冒烟（软件主控经真实 ssh_run_command 启动 1 次生成 + 1 次独立评分，≤2 次新增调用）；以回执完整性（E1）与流程合规可复现性（E2）为工程主端点（均二元可判），父判定失败数跨轮差异（0 vs 1 例 A4）仅作内部一致性描述性观察（O1，零推断统计）。不接受任何临床端点。

方法：治理机制包括回执驱动（run_receipt 逐级落盘与前后回执哈希链）、哈希契约（确定性 JSON 序列化哈希与原始文件字节哈希两类语义分立）、执行期修订披露（含超出预设 HTTP400-only fallback 批准范围的两笔网络恢复，如实披露为工程偏离）、自然停止规则（父失败数 <5 即停，候选自进化五腿均未触发）、执行通道按运行分层标注（前两轮回执=test controller via SSH；本轮冒烟回执=oph native ssh_run_command；real Baillian Qwen；formal/clinical 声明字段均 false，claim 与 validated 分属冒烟/审计 summary）、服务器端只读审计（audit.py，32/32 项）与数据边界（逐例报告/评分内容与密钥留驻服务器，本机仅聚合计数与哈希）。冒烟运行纪律：失败即停、不自动重发、自动重试 0、单并发、单百炼端点、输出上限 4096 tokens；冒烟累计至 49/60 后，剩余实验额度全部冻结不再使用。

结果：独立复核决策为 supported（8 条主张全部受支持）。冒烟：

run_id=oph-app-paper-smoke-20260907 状态 completed，2/2 次新增调用成功（qwen3.7-plus 1 次、qwen3.7-max 1 次），单任务 engineering_zero_fail_reports=1/1，累计总调用尝试 49 次（冻结预算上限 60 内），回执/执行器/冒烟脚本哈希指纹齐备，新增已知 token 32,119、累计已知 token 1,931,621。服务器端只读审计：32/32 项全部通过，状态 completed_natural_stop，local_parse_normalizations=0；live-acceptance 轮 20/20 次新增调用成功（qwen3.7-plus 10 次、qwen3.7-max 10 次），累计总尝试 47 次，max_completion_tokens=3177（低于 4096 上限）；审计重算父臂汇总 tasks=10、engineering_zero_fail_reports=9、failure_reports=1（唯一失败条目 A4）、report_format_failures=0、critical_failure_reports=0；同批冻结输入复验通过（same_frozen_inputs_as_prior、ten_deidentified_inputs、prior_receipt_unchanged 均为 true），先前 repair-v2 回执未被改动；审计运行与冒烟运行记录 runner_sha256 相同（478195369dcea00e8cf80ee78b954f45398e1c153f08a253a8e60d6800bc72b1）。

结论（范围限定）：在已登记复核支持的范围内（live-acceptance 32 项审计 + 软件主控冒烟；decision=supported，C1-C8），运行回执完整、计数闭合，并按预置停止规则与调用纪律合规终止；软件主控原生 SSH 执行链连通。前轮 repair-v2 的历史回执自述 <5 自然停止（sha256 a239b223...），但该轮含两笔已披露的越范围网络恢复，其聚合未在本 campaign 登记为 experiment，仅作历史背景、不并入合规判定。两轮父判定失败数差异（前轮 0 vs 本轮 1 例 A4）为描述性观察；本研究不构成临床有效性、跨患者泛化或候选分支有效性的任何证据。

注册与声明：方案已冻结登记为 study v1（contentHash sha256:19966e215cf68d4e7135f0a009ff565c0b25f43cc88f329e55f3db62aae3602d）；独立结果复核 decision=supported（reviewId 对应 artifactId document-resultsreview-independent-results-review）。本稿写作阶段使用 LLM 辅助（见「AI 使用声明」）；无 LLM 作者。

1 引言

1.1 背景

大语言模型在医疗健康领域的采用速度很快，业界随即呼吁标准化的报告规范 [4 TRIPOD-LLM]；医学影像 AI 的发表规范（CLAIM）强调科学结果必须可复现、发表必须遵循科学出版的基本准则 [1]；针对含 AI 干预的临床试验，CONSORT-AI 扩展建议对 AI 干预的输入输出处理、人机交互与错误案例分析作清晰描述 [2]；针对临床决策支持系统的早期阶段评价，DECIDE-AI 提供了多利益相关方共识的报告规范 [3]。上述规范的共同取向是：透明度、人工监督、任务特异的表现报告与可复现性 [4]。

与此同时，「LLM 评价 LLM」作为自动化质量控制的方案被广泛讨论：MT-Bench 与 Chatbot Arena 的研究系统考察了 LLM-as-a-judge 的使用与局限，包括位置偏倚、冗长偏倚、自增强偏倚以及有限的推理能力 [5]；进一步研究指出自偏好偏倚--LLM 评委给自己的输出打分高于他人输出，而人类标注者认为二者质量相当 [6]。在「模型自我改进」方向上，Self-Refine 提出由同一个 LLM 作为生成器、反馈提供者与精炼器进行迭代自反馈，作者报告其输出被人类与自动指标偏好 [7]；而另一项针对推理的研究则提示，没有外部反馈时 LLM 难以自我纠正，某些情况下自纠正后表现反而下降 [8]。对 LLM 的审计，文献提出治理、模型与应用三层审计彼此互补的框架，同时坦承对审计能达成什么应保持现实预期 [9]。

1.2 缺口

上述报告规范多面向预测模型、临床试验或早期临床评价场景，而「生成-自动评价」型 LLM 流水线在非临床的工程验收场景下如何组织可审计的运行记录、如何让「流程合规、回执完整」本身成为可二元判定、可被独立复核的端点，仍缺少成文的方法学示例。LLM-as-judge 与自偏好的既有边界提醒我们：单一家族模型担任评委时，任何「零失败」的工程结果都必须被限定在其工程语境内陈述，不得外推为质量或临床含义；候选「自进化」腿未被触发不等于已验证。已有审计文献亦提示审计手段自身的能力边界 [9]，这对「服务器端只读审计」这类应用层审计的定位具有直接参考意义。

1.3 目的

本研究的目的不是评价任何模型或报告的质量，而是报告一项方法学（工程可复现性）验收：

1. 检验在同一批 10 个冻结脱敏 development 任务（error-enriched hard92 包按行序前 10，非无偏子集）上，Qwen-only debug-json 单臂流水线经两轮真实验收（repair-v2、live-acceptance；同批运行级重复验收，非独立复制、非 20 例独立样本）的运行回执是否完整且内容自治（E1），两轮是否均按预置停止规则与调用纪律合规终止（E2）；
2. 把父判定失败数跨轮差异（前轮 0 vs 本轮 1 例 A4）作为内部一致性描述性观察（O1）如实报告，不做推断统计；
3. 以最小软件执行链冒烟验证软件主控经真实 ssh_run_command 启动流水线的原生执行链（S1），不增加统计信息量。

本研究不接受任何临床端点；源方案中的临床阈值（0.85）不在本研究范围内。

2 方法

2.1 设计与登记

本报告为运行级 (run-record) 方法学报告：分析单位是运行回执而非患者。研究设计为 Qwen-only 单臂流程（生成 qwen3.7-plus + 评分 qwen3.7-max，评分使用独立上下文），无对照臂、无随机化、无组间比较；主对照为「既有计划阈值/规则（父失败 <5 自然停止、预算上限 60 [本轮可用上限 49]、输出上限 4096、自动重试 0、单百炼端点/单并发）与观测的一致性」，次对照为两轮内部一致性描述（0 vs 1 例 A4 fail）。

方案已冻结为 study v1 并登记（登记文档 study-55f3db62aae3602d.json；contentHash sha256:19966e215cf68d4e7135f0a009ff565c0b25f43cc88f329e55f3db62aae3602d）。研究问题、端点与停止规则（主张-证据门 S1、引用门 S2、冒烟停止规则 S3、越界即停 S4、返修闭环 S5、变更门 S6、方案确认门 S7）均在该文档中冻结。方案经聊天确认（S7）后，preparation 预设通过并登记 handoff（document-handoff-experiment-preparation），随后 experiment/resultsreview/manuscript 版本链按序登记。

端点（均二元可判，来自已确认 study v1）：

- E1 回执完整性（主）：两轮 run_receipt/audit 聚合字段齐备、计数闭合；
- E2 流程合规可复现性（主）：两轮均按 <5 自然停止、候选五腿 not_executed 且调用行闭合、自动重试 0、单端点/单并发/输出上限合规、修订全部披露、两轮输入同批；
- O1 内部一致性观察（描述性、零推断统计）：父判定零失败 10/10 vs 9/10（1 例 A4 fail）；
- S1（冒烟端点）：软件主控真实 ssh_run_command 启动、回执完整、经 experiment 文档登记成功。

注：端点编号 S1（冒烟端点）与停止规则 S1（主张-证据门）为 study v1 中的既有符号复用；本文沿用登记口径，正文以「冒烟端点」与「主张-证据门」区分，二者含义不同。

独立结果复核（resultsreview-509e636ffa99ec51.json）结论为 supported，8 条主张全部受支持；其 reviewId 对应 artifactId document-resultsreview-independent-results-review；主张分别绑定冒烟 experiment 版本（rav_4a6648c8-b47d-4ca5-afc4-ab3a98ae74b3）与审计 experiment 版本（rav_ef12ad26-0164-47eb-add6-b308eefb26ca）。

2.2 研究对象与数据边界

- 研究对象：10 个冻结脱敏 development 任务（error-enriched hard92 包按行序前 10，非无偏）在 repair-v2 与 live-acceptance 两轮中的运行记录（运行级对象；第二轮输入与先轮同批，run_receipt.prior_receipt=a239b223...），另加软件主控冒烟的单任务运行记录。
- 冒烟输入：沿用同一冻结载荷中的首个任务（按 manifest 行序第 1 个），不新取任务；冒烟是重复执行而非新增独立样本，不并入 10 任务主分析。
- 数据边界：原始影像、患者标识、逐例报告与逐例评分全文留在授权服务器；远端仅发送脱敏缓存文本证据与账本；BAILIAN_API_KEY 只在服务器进程内加载（存在性硬门），密钥不复制到本机、不打印；本机与产出文件只含聚合计数、型号、哈希、方法与回执结构。
- 执行通道标注（按运行分层）：①两轮验收（repair-v2、live-acceptance）由外层测试控制经 SSH 执行，其 run_receipt 字段 execution_channel="test controller via SSH; application coordinates preparation and independent review"（本轮审计复算未改动该字段）；②本轮冒烟由软件主控 oph 原

生 ssh_run_command 启动，冒烟回执 execution_channel="oph native ssh_run_command; real Baillian Qwen"；③两个 experiment 登记文档包络字段均为 executionChannel=ssh-engineering；formal_backend_claim=false、clinical_validation_claim=false 属冒烟 summary，formal_backend_validated=false、clinical_validation=false 属审计 summary。正式隔离后台未装配、未验证，两轮与冒烟均为 SSH 工程通道而非正式隔离后台执行。

2.3 流水线描述

被验收的流水线为 Qwen-only debug-json 单臂流程：父臂以 qwen3.7-plus 为生成器对 10 个冻结任务各生成 1 份报告（debug-json 输出合同），父臂以 qwen3.7-max 为评委在独立调用上下文中按评分 schema 逐份评分（每任务 1 次，共 10 次）；评委仅单一 Qwen 家族（qwen3.7-max），不是正式方案中的三家族独立评委设计（该排除性背景可追溯至 experiment_handoff.md 历史节与既有计划评审材料，属背景陈述而非本 campaign 登记主张）。流水线还预置了候选「自进化」五腿--optimizer（候选优化器）、semantic_gate（语义门控）、candidate_generation（候选生成）、candidate_judging（候选评审 J1）、secondary_judging（候选评审 J2，可选项）--但两轮运行中该五腿均未执行（触发条件为父失败数 ≥ 5 ，未满足）；未执行腿在报告与回执中逐腿显式标注为 not_executed，不表述为流程缺陷，也不表述为候选已验证。

运行约束（两轮与冒烟共用口径）：python3 标准库、无第三方包；唯一端点 <https://dashscope.aliyuncs.com/compatible-mode/v1/chat/completions>（百炼兼容模式）；单并发顺序执行；每次输出 max_tokens ≤ 4096 ；自动重试 0；任务规模 10、至多 1 轮候选且未触发、累计总尝试 ≤ 60 （live-acceptance 后为 47/60，冒烟至多新增 2 次使累计 $\leq 49/60$ ）。

2.4 治理机制

回执驱动：每次运行产出 run_receipt.json（live-acceptance：schema_version=qwen_engineering_receipt_v2），记录各阶段状态（prepare/parent_generation/parent_judging/parent_aggregate 为 completed；optimizer 至 final_aggregate 五个候选阶段为 not_executed）、prior_receipt 链（指向先轮回执路径与 sha256）、来源文件哈希、计数、型号与逐调用元数据；阶段 (10) 收尾聚合与回执生成在自然停止下仍然执行。两轮回执哈希：repair-v2=a239b223ccc8b873e73e8652d92d492eb0c4839ce278f93ad7a009ffe4721be4；live-acceptance=a66bf2fb3e8b2a203ef053dae29d1cf5a6dc58e6e96b551691f09e76d2eb9d81。

哈希契约：hash_contract.md 定义两类哈希语义--确定性 JSON 序列化哈希与原始文件字节哈希分立；执行器版本以 runner sha256 链记录（live-acceptance 与冒烟共用 runner 478195369dcea00e8cf80ee78b954f45398e1c153f08a253a8e60d6800bc72b1；repair-v2 为修订链 c1e35845→22ce9a04→3ae045bf→1e6cc222）。

修订披露：前轮执行期存在三笔已披露修订--transport-recovery-01（一次手动网络恢复，同模型同冻结输入）、dns-recovery-02（HTTP 发送前 DNS 失败后一次手动恢复，TLS/redirect 未放宽）、local-parse-normalization-03（单键名规范化，评分与文本值不变、原响应保留、无额外 HTTP 调用）；两笔网络恢复超出方案预设 HTTP400-only fallback 的批准范围，按工程偏离如实披露；自动重试保持 0，失败尝试全部保守计入尝试数。本轮（live-acceptance）local_parse_normalizations=0。

自然停止规则：父臂失败报告数 < 5 即自然停止（stop_reason=parent_failures_below_5），不启动候选分支；不因结果修改评分或阈值（candidate_not_forced）。

授权记录：远端 runtime_authorization.json (record_type=internal_run_record、signature_status=no_formal_signature)，为内部运行记录，非正式签名批准。历史事实：两轮工程运行期（方案确认前）preparation 预设 workflow 曾返回 HTTP 409「请先在聊天中确认当前方案版本」，该历史事实在其产物中如实保留，自定义 workflow 不冒充预设已通过；本轮 study v1 经聊天方案确认后 preparation 预设已正常通过并登记 handoff (document-handoff-experiment-preparation)。

服务器端只读审计：live-acceptance 运行目录内置 audit.py (32 项检查)，在服务器端只读重算全部检查；审计项覆盖回执终态、prior 回执未变、prior 尝试结转、当前授权记录、配置/清单/授权哈希、源文件未变、同批冻结输入、10 个脱敏输入、原始治理保留、runner 哈希、服务器环境与传输记录、formal 声明缺席、请求/响应/解析哈希、型号身份、仅百炼端点、请求与完成参数、评分 schema 与哈希、规范化保全分值、成功响应 ID 唯一、新调用全部完成、尝试计数、已知 token 计数、输出上限、尝试顺序、单并发、无自动重试、父汇总重算、父生成与评分完整、停止规则、候选未被强启（共 32 项，逐项见 audit.json/experiment 文档）。前轮 repair-v2 另有服务器端确定性审计 audit_receipt.py (25/25，历史记录，非本 campaign 主张)。审计逐项复算在服务器完成，本机不做远端逐项重放（见局限）。

2.5 软件主控原生 SSH 冒烟（唯一新增执行腿）

- 目的 (S1 端点)：验证软件主控经真实 ssh_run_command 的原生执行链连通性 (oph 原生 ssh_run_command 真实调用百炼 Qwen)；不构成独立临床样本、不改变原 10 任务主分析、不增加统计信息量。
- 输入：两轮同一冻结载荷（同批 10 冻结脱敏任务）中的首个任务；运行记录 source_input_sha256=49ad456dc7146a432ce750fa97f7feae7e4fcf8be0ada321adce990176b0dd91。
- 调用：1 次生成 (qwen3.7-plus) + 1 次独立上下文评分 (qwen3.7-max，不复用生成上下文)；最多新增 2 次调用；累计总尝试 $\leq 49/60$ 。
- 纪律：失败即停（任一次失败立即中止并保留现场回执与失败元数据）；不自动重发、无 fallback、自动重试 0；单并发顺序；max_tokens ≤ 4096 ；单百炼端点；仅脱敏缓存文本载荷。
- 保存与登记：独立保存远端 run 目录与回执 (run 目录 /data1/20251113/AntiVEGF/oph-app-paper-smoke-20260907，app_smoke.py 薄封装位于 live-acceptance 运行目录；逐例内容留驻服务器，本机只收聚合与哈希)；执行经真实 ssh_run_command 成功后由主控登记 experiment 版本文档 (executionChannel=ssh-engineering；formal_backend_claim=false；no_formal_signature 表述沿用)。
- 收口：冒烟完成即止；冒烟不并入 10 任务主分析、不触发任何统计端点；冒烟后剩余实验额度全部冻结不再使用。

2.6 分析计划

全部端点均为工程二元判定或描述性观察：E1/E2 依据两轮 run_receipt/audit 聚合字段与计数闭合判定；O1 仅报告 0 vs 1 例 A4 的跨轮描述，零推断统计、无置信区间、无假设检验。任务子集为 error-enriched 非无偏子集，禁止外推与跨运行「复制成功」表述。稿件写作与复核过程零实验模型调用。

3 结果

结果按独立复核 (resultsreview-509e636ffa99ec51.json, decision=supported) 中受支持的 8 条主张逐一展开；每条主张文本逐字保留，其后给出对应产物。主张与产物的对应关系见表 1。

表 1 主张-证据产物映射（主张编号与正文引用一致；字段值见 experiment/audit 文档原文，本文不另列）

主张	绑定 experiment 版本 (artifactVersionId)	对应产物
C1-C3	rav_4a6648c8-b47d-4ca5-afc4-ab3a98ae74b3 (冒烟 experiment-4894ae70bd4adc68.json)	冒烟 run_receipt/聚合：run_id、状态、调用计数、汇总、 哈希指纹、tokens
C4	rav_ef12ad26-0164-47eb-add6-b308eeffb26ca 与 rav_4a6648c8-b47d-4ca5-afc4-ab3a98ae74b3 (审计与冒烟两文档)	两文档 runner_sha256 字段一致性
C5-C6	rav_ef12ad26-0164-47eb-add6-b308eeffb26ca (审计 experiment-2b8c1f2504d6a52e.json)	audit.py 服务器端 32 项检查输出 (audit.json/experiment 文档)
C7	rav_ef12ad26-0164-47eb-add6-b308eeffb26ca	审计重算父臂汇总 (audit.json parent_summary)
C8	rav_ef12ad26-0164-47eb-add6-b308eeffb26ca	same_frozen_inputs_as_prior / ten_deidentified_inputs / prior_receipt_unchanged 三 项检查

3.1 软件主控原生 SSH 冒烟（主张 C1-C3）

主张 C1（逐字）：软件主控冒烟运行 run_id=oph-app-paper-smoke-20260907 状态 completed，执行通道为 oph 原生 ssh_run_command 真实调用百炼 Qwen；新增调用 2/2 全部成功 (qwen3.7-plus 1 次、qwen3.7-max 1 次)，automatic_retries=0，formal_backend_claim=false、clinical_validation_claim=false。

对应产物：冒烟 experiment 文档 (experiment-4894ae70bd4adc68.json) summary 字段记录 status=completed、new_call_attempts=2、new_call_successes=2、models={qwen3.7-max:1, qwen3.7-plus:1}、automatic_retries=0、execution_channel="oph native ssh_run_command; real Baillian Qwen"、formal_backend_claim=false、clinical_validation_claim=false，与主张逐项一致。该腿验证的是软件主控原生执行链连通性 (S1 端点)，不是独立样本，不改变 10 任务主分析。

主张 C2（逐字）：冒烟运行单任务汇总为 engineering_zero_fail_reports=1/1、failure_reports=0、report_format_failures=0、critical_failure_reports=0，累计总调用尝试 49 次（冻结预算上限 60 内）。

对应产物：冒烟 experiment summary 嵌套汇总 tasks=1、engineering_zero_fail_reports=1、failure_reports=0、report_format_failures=0、critical_failure_reports=0、failed_item_counts={}, total_call_attempts=49。49 次 = 两轮 47 次 (repair-v2 27 次 + live-acceptance 20 次) + 冒烟 2 次；未超出冻结预算上限 60。

主张 C3（逐字）：冒烟运行带完整哈希指纹：receipt_sha256=c0a2408521eaa1c1d767e3fa9512ade5ca123ab511f4e41d632f4f92d98fe1eb、runner_sha256=478195369dcea00e8cf80ee78b954f45398e1c153f08a253a8e60d6800bc72b1、app_smoke_sha256=608b08ace1843008cdb2f752ced3cd21130d06f7bcc4e4a458318e8ec068914f；本轮新增已知 token 32,119，累计已知 token 1,931,621。

对应产物：冒烟 experiment summary 记录上述三枚哈希与 new_known_tokens=32,119、cumulative_known_tokens=1,931,621。已知 token 合计非完整账单（前轮一次 URLError 的服务端计费未

知)，见局限 L4。

3.2 live-acceptance 服务器端只读审计与调用纪律（主张 C4-C6）

主张 C4（逐字）：live-acceptance 服务器端审计运行与冒烟运行记录的 runner_sha256 相同（478195369dcea00e8cf80ee78b954f45398e1c153f08a253a8e60d6800bc72b1），两个 experiment 文档的执行代码指纹一致。

对应产物：审计 experiment 文档（experiment-2b8c1f2504d6a52e.json）与冒烟 experiment 文档（experiment-4894ae70bd4adc68.json）的 runner_sha256 字段均为 478195369dcea00e8cf80ee78b954f45398e1c153f08a253a8e60d6800bc72b1。

主张 C5（逐字）：服务器端只读审计 32/32 项检查全部通过（all_checks_pass=true、passed=32、total=32），状态 completed_natural_stop，local_parse_normalizations=0；formal_backend_validated=false、clinical_validation=false。

对应产物：审计 experiment summary 与 audit.json 记录 all_checks_pass=true、passed=32、total=32、status=completed_natural_stop、local_parse_normalizations=0、formal_backend_validated=false、clinical_validation=false。32 项检查的逐项布尔值见 audit.json checks 对象（本机聚合副本）与服务器端 audit.py 输出。

主张 C6（逐字）：该运行新增 20 次调用全部成功（qwen3.7-plus 10 次、qwen3.7-max 10 次），累计总尝试 47 次；max_completion_tokens=3177 低于 4096 上限；single_concurrency、no_automatic_retry、completion_limit、stopping_rule、candidate_not_forced 检查均为 true。

对应产物：审计 experiment summary：new_attempts=20、new_successes=20、models={qwen3.7-plus:10, qwen3.7-max:10}、total_attempts=47、max_completion_tokens=3177；checks 中 single_concurrency、no_automatic_retry、completion_limit、stopping_rule、candidate_not_forced 均为 true。47 次 = 前轮 repair-v2 27 次 + 本轮 20 次；47 在预算 60 内。

3.3 父臂汇总与自然停止（主张 C7）

主张 C7（逐字）：审计重算父臂汇总：tasks=10、engineering_zero_fail_reports=9、failure_reports=1（唯一失败条目 A4，failed_item_counts={A4:1}）、report_format_failures=0、critical_failure_reports=0，parent_summary_recomputed=true；失败数低于停止阈值，自然停止未强启候选分支。

对应产物：audit.json/experiment parent_summary：tasks=10、engineering_zero_fail_reports=9、failure_reports=1、failed_item_counts={A4:1}、report_format_failures=0、critical_failure_reports=0，parent_summary_recomputed=true；run_receipt stop_reason=parent_failures_below_5。即：10 份报告中 9 份零失败，1 份报告在评分清单条目 A4 未通过（A4 为评分清单条目编号，逐例判定内容按数据边界留驻服务器，本稿不展开其内容）；失败报告数 1 低于停止阈值 5，故未触发、未强启候选分支（optimizer 至 secondary_judging 五腿均为 not_executed）。1 份 A4 失败是实验结果而非流程故障。

3.4 同批冻结输入复验与回执链不变（主张 C8）

主张 C8（逐字）：审计确认 same_frozen_inputs_as_prior=true、ten_deidentified_inputs=true、prior_receipt_unchanged=true：本次验收使用与先前一致的 10 个冻结脱敏输入（同一批次重复验收），先前 repair-v2 回执未被改动。

对应产物：audit.json/experiment checks 中 same_frozen_inputs_as_prior、ten_deidentified_inputs、prior_receipt_unchanged 均为 true；run_receipt.prior_receipt 指向 repair-v2 回执（sha256 a239b223ccc8b873e73e8652d92d492eb0c4839ce278f93ad7a009ffe4721be4），审计确认其未被改动。这意味着本轮与 repair-v2 是同一批 10 个冻结脱敏输入的运行级重复验收（非 20 例独立样本、非独立复制）。

3.5 本机可核验的回执算术（复核限定）

按独立复核限定，本机仅核验聚合与回执算术并全部闭合：47=27+20（live-acceptance 累计尝试 = 前轮 27 + 本轮 20）；1,899,502=949,535+949,967（live-acceptance 累计已知 token = 前轮 949,535 + 本轮新增 949,967）；1,931,621=1,899,502+32,119（冒烟累计已知 token = live-acceptance 累计 + 冒烟新增 32,119）；3177≤4096（最大完成长度未超上限）；prior receipt sha256 a239b223... 未变。逐病例报告与评分内容、服务器端传输级属性与逐调用哈希不可在本地重放（见局限 L5、L10）。

4 讨论

4.1 结果解读与证据范围

在登记范围内，8 条主张全部受支持（decision=supported）。就协议端点而言：在已登记复核支持的范围内（resultsreview decision=supported，C1-C8 绑定 live-acceptance 32 项审计与冒烟两个 experiment 文档），E1（回执完整性）与 E2（流程合规可复现性）的字段齐备、计数闭合、自然停止、候选未执行、调用纪律与修订披露在审计与冒烟产物上成立；前轮 repair-v2 仅作历史背景（其含两笔已披露的越范围网络恢复与一笔本地解析规范化，聚合未在本 campaign 登记为 experiment，不并入本判定）；O1 以描述性方式报告跨轮失败数差异；S1（冒烟端点）验证了软件主控原生 SSH 执行链。需要强调：上述「成立」全部限定在本研究登记的方法学/工程验收范围内，不携带任何临床含义--形式化声明字段（formal_backend_claim=false、clinical_validation_claim=false、formal_backend_validated=false）在所有产物中显式保留，本稿不将研究验证写作临床可用。

4.2 跨轮差异（前轮 0 vs 本轮 1 例 A4）：历史背景与描述性观察

前轮 repair-v2 的历史回执（run_receipt sha256 a239b223...，为 live-acceptance 回执的 prior_receipt）载明父判定 10/10 零失败；本轮 live-acceptance 审计重算父汇总为 9/10 零失败 + 1 例 A4 失败。必须明确证据范围：前轮 repair-v2 聚合（10/10 零失败）属于早前会话产物，未在本 campaign 登记为 experiment 文档，本稿不将其作为绑定主张（binding claim）；跨轮差异仅作为历史背景下的描述性观察报告，零推断统计。同一批输入在两轮中产生 0 与 1 例失败差异的可能来源（模型版本行为、传输/解析状态、判定边界，以及前轮两笔手动网络恢复与一次本地解析规范化改变了判定输入链路等结构性因素）在本研究数据中无法区分，本稿不作归因推断；该观察的意义在于如实报告运行级重复验收中的轮间变化，而不是声称任何稳定性结论。1 份 A4 失败已按实验结果处理：未修改评分或阈值（candidate_not_forced=true），候选分支未被执行，因此无任何候选有效性证据，也不存在「强启候选掩盖失败」的路径。

4.3 LLM-as-judge 单评委局限与候选腿未执行的定位

本流水线的评委为单一 Qwen 家族模型 (qwen3.7-max)，生成器同为 Qwen 家族 (qwen3.7-plus)。文献已系统记录 LLM-as-a-judge 的位置偏倚、冗长偏倚、自增强偏倚与有限推理能力 [5]；自偏好研究进一步表明 LLM 评委倾向给自己家族的输出更高评分，而人类标注者认为质量相当 [6]。因此，「engineering_zero_fail_reports」一类结果只描述该子集在该通道、该评委口径上的管线行为，本稿不将其表述为报告质量、医生偏好或临床可用的任何代理；对自偏好/LLM-as-judge 偏倚，本稿只陈述文献边界，不作「已缓解」声称。

候选「自进化」五腿 (Self-Refine 式同模型自反馈设计 [7]) 在两轮中均因父失败数 <5 而未触发。文献对无外部反馈的自纠正效果存在相反证据：Self-Refine 作者报告迭代自反馈的收益 [7]，而针对推理任务的研究提示 LLM 难以在没有外部反馈时自我纠正、有时自纠正后表现下降 [8]。本研究不介入该争论：未触发腿在全部产物中逐腿标注 not_executed，本稿只陈述「未触发 ≠ 已验证」，既不把未执行表述为候选有效，也不表述为流程缺陷。

4.4 报告规范与审计框架的适配与边界

本文是方法学/工程可复现性报告，而不是预测模型研究、临床试验或临床决策支持的早期评价研究；因此 TRIPOD-LLM (19 主项/50 子项，强调透明度、人工监督与任务特异表现报告) [4]、DECIDE-AI (面向 AI 决策支持系统的早期临床评价) [3]、CONSORT-AI (含 AI 干预的临床试验) [2] 与 CLAIM (医学影像 AI 研究) [1] 在本研究中作为报告要素的参照而非被完整执行的清单：本稿借鉴其「透明声明、范围限定、错误案例如实呈现、输入输出与人机交互可描述」的取向，并以显式字段 (formal_backend_claim=false 等) 与显式局限替代临床规范中的适用项。本稿不宣称满足上述任一规范的完整合规；投稿前将按目标刊社模板评估适用的报告摘要/清单 (见「稿件元信息」)。

在审计定位上，服务器端只读审计 (32/32 项) 属于应用层审计的一种实践：文献提出的治理-模型-应用三层审计框架提示，应用层审计应与其他层互补，同时审计本身的能力边界须保持现实预期 [9]。本研究据此把审计结论限定为「对已登记运行的只读重算通过」，不把审计通过表述为对模型或提供方的治理审计结论。写作定位上，同刊 (npj Imaging) 的 AutoQC-Bench 文章 (自动质量控制模型与基准，含量化阈值的质量控制流水线) [10] 为「带量化阈值的影像数据处理质量控制」类报告提供了同刊先例，本研究在结构上参照其「工程性、可量化、边界明确」的写法，但不将其研究对象与本研究的任务集等同。

5 局限

逐条陈述如下 (来自独立复核 limitations 与方案 counterEvidence，未弱化、未删减)：

1. 非 20 例独立样本：两轮为同一批 10 个冻结脱敏任务 (error-enriched hard92 行序前 10，非无偏子集) 的运行级重复验收，不是 20 例独立样本、不是独立复制；子集非无偏，禁止外推与推断统计。冒烟是对同批任务中首个任务的重复执行，不是新增独立样本，也不并入 10 任务主分析；两轮运行均不构成临床有效性或跨患者泛化证据 (formal/clinical 声明均为 false)。
2. 无临床评审、无临床端点：评委为单一家族 Qwen (qwen3.7-max)，非医生评价、非三家族独立评委；0.85 源方案临床阈值未涉及；本研究不评估报告质量优劣，不替代医生评价或患者结局。
3. 候选腿未执行：候选自进化五腿两轮均未执行；未触发 ≠ 已验证，无候选有效性证据；1 份 A4 失败是实验结果而非流程故障，未改动评分或阈值强启候选 (candidate_not_forced=true)。

4. tokens 非账单：已知 token 合计 (1,931,621) 不构成完整账单--早前一次 URLError 的服务端计费仍未知；两笔失败尝试 (URLError 发送状态未知、DNS 失败发生在 HTTP 发送前无模型响应) 保守计入尝试数，不计入已知 token 和。

5. 服务器端属性不可本地重放：单并发时序、恢复同冻结载荷、TLS/redirect 属性、逐调用哈希与逐例评分仅存于服务器；本机仅核验聚合与回执算术 ($47=27+20$ 、 $1,899,502=949,535+949,967$ 、 $1,931,621=1,899,502+32,119$ 、 $3177 \leq 4096$ 、prior receipt sha256 a239b223... 未变)，未执行远端逐项复算；完整病例级重放须在服务器权限范围内进行。

6. 正式后台未装配：正式隔离后台未装配、未验证 (formal_backend_validated=false)；前两轮验收经 test controller via SSH (其回执 execution_channel 字段)，本轮冒烟与审计复算经软件主控 oph 原生 ssh_run_command；均为 SSH 工程通道而非正式隔离后台执行，连通性通过不等于正式链路通过。

7. 授权无正式签名与预设历史：授权记录为内部运行记录 (runtime_authorization.json，record_type=internal_run_record、signature_status=no_formal_signature)，非正式签名批准。两轮工程运行期 (方案确认前) preparation 预设 workflow 曾返回 HTTP 409 (历史事实保留)；本轮方案确认后 preparation 预设已通过并登记 handoff (document-handoff-experiment-preparation)。

8. 工程偏离披露：前轮两笔网络恢复 (transport-recovery-01、dns-recovery-02) 超出方案预设 HTTP400-only fallback 的批准范围，属用户指令驱动的工程偏离，已按修订披露并保守记账；一笔本地解析规范化 (local-parse-normalization-03) 不改动评分与文本值、无额外 HTTP 调用；本轮 local_parse_normalizations=0。

9. 冒烟信息量有限：冒烟腿为 1 任务工程连通性验证，不增加统计信息量；冒烟 summary 与 ssh stdout JSON 的精确相等性未见于本地 experiment 文档，未纳入主张；冒烟后剩余实验额度全部冻结不再使用。

10. 跨轮差异不作主张：前轮 repair-v2 聚合 (10/10 零失败) 未在本 campaign 登记为 experiment 文档；跨轮比较 (前轮 0 vs 本轮 1 例 A4 失败) 仅作为描述性观察，不构成主张，不做推断统计。

11. 报告规范未宣称合规：本文未完整执行 CLAIM/CONSORT-AI/DECIDE-AI/TRIPOD-LLM 任一清单 (适用性判定见 4.4)；LLM-as-judge 与自偏好偏倚未缓解、仅陈述边界。

12. 刊社信息缺项：Radiology: AI 官方投稿要求因 403 未能核验 (列为候选开放项)；npj Imaging 是否明确强制 CLAIM/TRIPOD 式影像 AI 清单未在已读页面确认 (仅确认 Nature Portfolio 通用报告摘要机制)；APC 金额未核验。

6 数据与代码可用性

6.1 存放位置 (服务器端)

- 轮 1 repair-v2 运行目录：/data1/20251113/AntiVEGF/oph-qwenonly-devtest-20260907-repair-v2 (run_receipt.json、runtime_authorization.json、逐调用回执、三份修订记录、dns_snapshot.json 等；run_receipt sha256 a239b223...) [执行：外层测试控制经 SSH；回执 execution_channel=test controller via SSH]。

- 轮 2 live-acceptance 运行目录：/data1/20251113/AntiVEGF/oph-qwen-live-acceptance-20260907 (run_receipt.json [sha256 a66bf2fb...]、audit.json、audit.py、test_verification.json、timeline.jsonl、app_smoke.py、逐调用回执等；audit.py 服务器端只读审计 32/32) [执行：外层测试控

制经 SSH；回执 execution_channel=test controller via SSH]。

- 冒烟运行目录：/data1/20251113/AntiVEGF/oph-app-paper-smoke-20260907（独立 run 目录，run_id=oph-app-paper-smoke-20260907；逐调用回执与聚合留驻服务器；登记见 experiment-4894ae70bd4adc68.json）〔执行：软件主控 oph 原生 ssh_run_command；回执 execution_channel=oph native ssh_run_command; real Bailian Qwen〕。

6.2 访问边界与披露（与 npj 数据可用性政策对齐）

npj 出版条件是作者须在无不当限制的前提下及时提供材料、数据、代码与相关协议，限制须在投稿时与稿件中披露。本研究的披露如下：

- 原始影像、患者标识、逐例报告与逐例评分全文不离开授权服务器，不进入公共仓库--此为发表所需披露的访问限制；
- 本机（可作为去标识聚合层开放）持有：登记文档（study/resultsreview/experiment/venue/evidence，见 campaign rc_6eb0b1bf-da7c-491e-b754-13b8593b44f5）、聚合材料（research/qwenonly-results-bundle-20260907/、research/antivegf-live-acceptance-20260907/{run_receipt.json,audit.json,report.md}、research/qwenonly_engineering_report_20260907.md、research/experiment_handoff.md、research/oph-paper-e2e-20260907/independent-review-original.json）、执行代码 SHA256（runner 478195369dcea00e8cf80ee78b954f45398e1c153f08a253a8e60d6800bc72b1；repair-v2 修订链 c1e35845→22ce9a04→3ae045bf→1e6cc222）与审计输出；
- 服务器端只读审计代码 audit.py（32 项）与 audit_receipt.py（25/25，前轮）以只读方式在授权服务器内提供；逐例级重放须在服务器权限范围内进行，需授权且计入回执；
- 本机与远端均不存放、不传输密钥值；模型调用凭证仅服务器进程内加载。

投稿时将按目标刊（npj Imaging）政策完成去标识聚合层数据的可用性陈述与必要的报告摘要文档；DOI/仓库位置待补（本稿不虚构存放链接）。数据访问请求将按上述访问边界评估。

7 AI 使用声明

- 本文研究对象为 Qwen-only 流水线：正文所述被验收对象（qwen3.7-plus 生成、qwen3.7-max 单评委评分、候选腿未执行）全部为研究客体，其行为与局限按登记回执如实报告，不因「研究对象是 LLM」而改变证据标准。
- 写作阶段 LLM 用途披露：本稿（v1 及其 v2 返修）由项目内部证据写作 Agent（evidence-writer 角色，oph 科研软件管线）依据登记文档与本机聚合材料撰写；LLM 在本稿写作中承担语言组织与格式整理（证据写作与稿件起草），未参与实验执行、未生成任何研究数字；全部主张逐字取自独立复核文档，全部数字与产物一一对应可追溯。稿件所用模型调用（冒烟与两轮验收）均已在「方法/结果/数据可用性」中披露并登记。
- 无 LLM 作者：按目标刊政策（LLM 不得列为作者；LLM 用途须在方法或相应位置披露；作者对原创性、准确性与完整性负全责），本稿作者名单留待真实课题组成员填写，LLM 不署名。
- 稿件写作与复核阶段零实验模型调用；检索与示例学习不构成参数微调，本文不涉及模型训练或微调。

8 参考文献

格式说明：条目以本 campaign 已登记 evidence key 为锚；作者/卷期/页码/DOI 于 2026-09-07 经 Crossref API 与 arXiv 官方页逐条核验（见「10 返修响应表」F4）；登记 evidence 仅保证题名/URL/摘要片段等字段可追溯，书目字段以本行核验记录为准。除下列已登记文献外，本稿未引用任何未登记外部文献。

1. Mongan J, Moy L, Kahn CE Jr. Checklist for Artificial Intelligence in Medical Imaging (CLAIM): A Guide for Authors and Reviewers. *Radiology: Artificial Intelligence*, 2020;2(2):e200029. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8017414/?report=classic>. DOI: 10.1148/ryai.2020200029. [登记 key : evidence-claim-2020-radiology-ai]
2. Liu X, et al. (CONSORT-AI 工作组) . Reporting guidelines for clinical trial reports for interventions involving artificial intelligence: the CONSORT-AI extension. *Nature Medicine*, 2020;26(9):1364-1374. URL: <https://www.nature.com/articles/s41591-020-1034-x>. DOI: 10.1038/s41591-020-1034-x. [登记 key : evidence-consort-ai-2020-natmed]
3. Vasey B, et al. (DECIDE-AI 专家组) . Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: DECIDE-AI. *Nature Medicine*, 2022;28(5):924-933. URL: <https://www.nature.com/articles/s41591-022-01772-9>. DOI: 10.1038/s41591-022-01772-9. [登记 key : evidence-decide-ai-2022-natmed]
4. Gallifant J, et al. The TRIPOD-LLM reporting guideline for studies using large language models. *Nature Medicine*, 2025;31(1):60-69. URL: <https://www.nature.com/articles/s41591-024-03425-5>. DOI: 10.1038/s41591-024-03425-5. [登记 key : evidence-tripod-llm-2025-natmed]
5. Zheng L, et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *NeurIPS*, 2023. arXiv:2306.05685. URL: <https://arxiv.org/abs/2306.05685>. [登记 key : evidence-mtbench-judge-2023-neurips]
6. Panickssery N, Bowman SR, Feng S. LLM Evaluators Recognize and Favor Their Own Generations. 2024. arXiv:2404.13076. URL: <https://arxiv.org/abs/2404.13076>. [登记 key : evidence-selfpref-2024-llm-judges]
7. Madaan A, et al. Self-Refine: Iterative Refinement with Self-Feedback. 2023. arXiv:2303.17651. URL: <https://arxiv.org/abs/2303.17651>. [登记 key : evidence-selfrefine-2023-llm-feedback]
8. Huang J, et al. Large Language Models Cannot Self-Correct Reasoning Yet. *ICLR*, 2024. arXiv:2310.01798. URL: <https://arxiv.org/abs/2310.01798>. [登记 key : evidence-selfcorrection-no-2024]
9. Mökander J, Schuett J, Kirk HR, Floridi L. Auditing large language models: a three-layered approach. *AI and Ethics*, 2023/2024;4(4):1085-1115 (online 2023-05-30) . DOI: 10.1007/s43681-023-00289-2. URL: <https://arxiv.org/abs/2302.08500> (arXiv 预印本) . [登记 key : evidence-llm-audit-three-layer-2023 ; v1 曾误写 Nature Machine Intelligence 与不存在的 DOI 10.1038/s42256-023-00713-8 , v2 已按 Crossref 更正]
10. Pan Z, Sonneck J, Nagel D, Hasenberg A, Gunzer M, Shi Y, Chen J. AutoQC-Bench: a diffusion model and benchmark for automatic quality control in high-throughput microscopy. *npj Imaging*, 2025;3:57. URL: <https://www.nature.com/articles/s44303-025-00117-8>. DOI:

10.1038/s44303-025-00117-8. [登记 key : evidence-npj-autoqc-bench-2025 ; 登记深度=元数据 ; 全文级核验留待投稿前]

9 附：登记锚点索引（可追溯性）

- 研究登记 campaign : rc_6eb0b1bf-da7c-491e-b754-13b8593b44f5 (documents/ 下 study/resultsreview/experiment/venue/evidence 均在此登记) 。
- study v1 : study-55f3db62aae3602d.json ; contentHash sha256:19966e215cf68d4e7135f0a009ff565c0b25f43cc88f329e55f3db62aae3602d 。
- 独立结果复核 : resultsreview-509e636ffa99ec51.json ; decision=supported ; reviewId 对应 artifactId document-resultsreview-independent-results-review ; 8 条主张原文另存于 research/oph-paper-e2e-20260907/independent-review-original.json 。
- 冒烟 experiment : experiment-4894ae70bd4adc68.json (key=ssh-experiment-app-paper-smoke-20260907 ; artifactVersionId rav_4a6648c8-b47d-4ca5-afc4-ab3a98ae74b3) 。
- 审计 experiment : experiment-2b8c1f2504d6a52e.json (key=ssh-experiment-live-acceptance-audit-20260907 ; artifactVersionId rav_ef12ad26-0164-47eb-add6-b308eefb26ca) 。
- 刊会画像 : venue-69a0b1e522207b1f.json (npj Imaging , venue-npj-imaging-2026) 。
- 实验准备 handoff : handoff-85601295f520ce5d.json (key=experiment-preparation) 。
- 稿件版本 : v1 已登记 (rav_10c82c34-2fea-489b-8113-1ab7701ea5a7) ; v2 (本稿) 为返修稿, 本地文件 research/oph-paper-e2e-20260907/manuscript_v2_20260907.md ; 三角色审稿意见与逐条响应见「10 返修响应表」 。
- 服务器端聚合副本 (本机只读引用) : research/antivegf-live-acceptance-20260907/{run_receipt.json,audit.json,report.md} ; research/qwenonly-results-bundle-20260907/ ; research/qwenonly_engineering_report_20260907.md ; research/experiment_handoff.md (顶部校订块) ; research/oph-paper-e2e-20260907/ (independent-review-original.json 与 ssh 步骤记录 st_0mtqv13ic0000w7kvgc.json 、 st_0mtqv2s0w0000h4ocda.json) 。

10 返修响应表 (v1→v2, 唯一一轮；三角色审稿 workflow st_0mtqvt5xz0000y4lk5m)

编号	审稿发现 (角色)	严重度	v2 处理	状态
F1	摘要结果段 run_id 误写 oph-app-paper-smoke-20260709 (contribution/methods)	major	摘要更正为 oph-app-paper-smoke-20260907, 与 experiment summary.run_id、主张 C1、§6.1、§9 全稿一致	已改
F2	§2.4/§5-7 将 preparation 预设 HTTP 409 写成当前状态 (contribution/methods)	major	改写为历史事实 (两轮工程运行期/方案确认前) + 本轮 preparation 预设已通过并登记 handoff (document-handoff-experiment-preparation) ; 局限 7 相应改写; §9 补 handoff 锚点	已改
F3	执行通道混同: 前两轮 test controller via SSH vs 本轮 oph 原生 ssh_run_command (methods)	major	摘要方法段、§2.2、局限 6 分层改写; §6.1 各目录加执行来源注; §2.1 加 study 口径调和句; 明确审计复算输出无 execution_channel 字段、包络字段 executionChannel=ssh-engineering 为两文档共同	已改
F4	参考文献书目字段超出登记证据且第 9 条期刊/DOI 虚构 (evidence)	major	10 条书目于 2026-09-07 经 Crossref/arXiv 逐条核验并更新: 第 9 条更正为 AI and Ethics 4(4):1085-1115 (DOI 10.1007/s43681-023-00289-2, online 2023-05-30), 删除虚构的 Nature Machine Intelligence 与 10.1038/s42256-023-00713-8; 补第 10 条作者与第 2/3/4 条卷期; 格式说明改为以核验记录为准	已改
F5	摘要结论「两轮均合规终止」超出 resultsreview 绑定范围 (contribution)	major	结论收窄为 claim-backed 范围 (live-acceptance 32 项审计 + 冒烟, C1-C8), repair-v2 仅作历史背景并注明其披露偏离与未登记; §4.1 同步	已改
A1	S1 符号双义 (端点 vs 停止规则, study v1 既有) (contribution)	minor	§2.1 加注说明并统一「冒烟端点/主张-证据门」区分	已改
A2	O1 未列「恢复/规范化改变判定输入链路」替代解释 (contribution)	minor	§4.2 可能来源清单补入该结构性因素	已改
A4	§9 未引用 handoff 登记锚点 (contribution)	minor	§9 补 handoff-85601295f520ce5d.json 条目	已改
V1	AI 披露未写明写作辅助工具 (evidence)	minor	§7 补充项目内部证据写作 Agent (evidence-writer 角色) 表述	已改
V2	数据仓库/DOI 与 reporting summary 为送审前阻断项 (evidence)	minor	保留「待补」并如实标注为投稿前阻断项; 作者/单位/利益冲突/伦理说明同	保持待补 (如实)
A3	无越界表述; [10] AutoQC 全文级核验留待投前 (contribution)	通过	§8 第 10 条标注全文级核验留待投稿前	已处理